

GPU Search

Asystent wyszukiwania modeli kart graficznych oparty na języku naturalnym

Wstęp i Cele Projektu

Ewolucja interfejsu wyszukiwania: od parametrów technicznych do intencji użytkownika.

Cel: Przekład mowy na dane

Celem projektu było stworzenie systemu, który rozumie swobodne zapytania użytkowników i mapuje je na konkretne rekordy techniczne.

Zapytanie: "Tania karta amd radeon posiadająca 8gb vram."



Baza danych: 40 lat technologii



Kaggle Dataset

Zbiór "GPU Specs from 1986 to 2026" zawierający tysiące rekordów technicznych.



Domena Publiczna

Licencja CCO pozwala na swobodne przetwarzanie i udostępnianie danych.



Specyfikacja

Od taktowania zegara po architekturę i przepustowość pamięci (VRAM, TFLOPS).

Przetwarzanie i Estymacja Kosztów

CENA ZA
GODZINĘ
USD

Wprowadziliśmy autorską metrykę kosztu wynajmu GPU opartą na trzech filarach:

$$\text{Price} = 2.0 + (0.00025 \cdot \text{TDP}) + (0.15 \cdot \text{TFLOPS}) + (0.000003 \cdot \text{VRAM})$$

Dzięki temu system potrafi interpretować pojęcia takie jak "tania" w kontekście rynkowym.

Analiza Strategii Wyszukiwania

Od podobieństwa semantycznego po deterministyczną ekstrakcję encji.

Metoda 1: BERT i Embeddings

Przekonwertowaliśmy parametry techniczne każdej karty na opisowe zdania w języku naturalnym, a następnie użyliśmy modelu **all-MiniLM-L6-v2**.

✂️ Obliczanie podobieństwa cosinusowego między zapytaniem a bazą.

📄 Dobra obsługa synonimów marek i architektur.

Wyzwanie: Liczby

Modele oparte na podobieństwie zdań często ignorują precyzyjne wartości liczbowe (np. 8GB vs 12GB), traktując je jako bliskie semantycznie, co dyskwalifikuje je w wyszukiwaniu sprzętu.

SOTA: LLM vs Modele Hybrydowe

Kryterium	Modele LLM (API)	Nasze podejście (NER)
Koszty	Wysokie (opłaty za tokeny)	Minimalne (lokalny model)
Opóźnienie	Sieciowe (zauważalne)	Błyskawiczne (CPU/Local)
Prywatność	Ryzyko wycieku danych	Pełna kontrola lokalna

Metoda 2: NER w spaCy

Named Entity Recognition

Zamiast szukać podobieństwa całych zdań, wyciągamy kluczowe "encji": Brand, VRAM, Budżet.

Wykorzystaliśmy polski model **pl_core_news_sm** wzbogacony o dedykowany moduł **EntityRuler**.



Logika rozpoznawania wzorców

Reguły Regex


Zastosowaliśmy wzorce do wykrywania jednostek:

```
label: "VRAM"  
regex: r"^\d+(,\d+)?$"  
tokens: ["gb", "gigabajt", "mb"]
```

Lematyzacja Naprawcza

Wiele terminów technicznych (CUDA, GB) wymagało ręcznej poprawy procesu lematyzacji w pipeline spaCy, aby uniknąć błędów odmiany.

Skuteczność Rozwiązania



Testy przeprowadzone na 100 unikalnych zapytaniach wygenerowanych przez LLM.

Główne błędy wynikały z trudnych form przymiotnika "tani" (np. "tanio" -> "tać").

Pytania?

Wnioski: NER to optymalna, deterministyczna metoda dla wyszukiwarek dziedzinowych.

Autorzy Projektu | GPU Search Assistant | 2026

Image Sources



https://www.lemon8-app.com/seo/image?item_id=7459645922255847982&index=0&sign=a1371d7074199941ade728aef654d3c4

Source: www.lemon8-app.com



<https://cdn.builtin.com/cdn-cgi/image/f=auto,fit=cover,w=320,h=200,q=80/sites/www.builtin.com/files/2024-05/transformer-neural-networks.jpg>

Source: [builtin.com](https://www.builtin.com)